



Projet 11 - Soutenance finale

Lifelong learning for never ended robot learning

Laetitia HAYE
Victoire MIOSSEC
Alexandre PRESA

jeudi 11 février 2021



Plan

1. Contexte & Objectifs
2. Méthode de benchmarking
3. État de l'art
4. Résultats
5. Conclusion & Perspectives




Plan


- 1. Contexte & Objectifs**
2. Méthode de benchmarking
3. État de l'art
4. Résultats
5. Conclusion & Perspectives

Un problème précis : la saisie d'objet

- Robotique
- Prédiction de la position du bras, de l'angle et de l'ouverture des mâchoires à partir d'images RGB-D
- Objectif de Lifelong learning : pouvoir apprendre à saisir de nouveaux objets sans perte d'efficacité sur les anciens objets ou apprendre de nouvelles tâches au robot autre que la saisie.




Lifelong learning



Adaptable



Tâches spécifiques




Catastrophic forgetting

- en apprenant de nouvelles tâches, les agents artificiels oublient comment traiter les précédentes
- lifelong learning : surmonter le “stability-plasticity dilemma”
- essentiel pour que les IA restent à jour malgré l’évolution de leur environnement



3 approches face au catastrophic learning

- Memory replay : “buffer” qui conserve des données des tâches précédentes
- Architecture growing : évoluer l'architecture du réseau de neurones généralement en ajoutant des paramètres
- Régularisation : appliquer une régularisation à la méthode d'optimisation de sorte à empêcher l'oubli des concepts précédemment appris.





Avantages et inconvénients de ces méthodes

Méthode	Memory replay	Architecture growing	Régularisation
Difficulté à éviter l'oubli	+++	+++	--
Utilisation mémoire	-	--	+++
Propriété des données	--	+++	+++

→ Pas d'approche parfaite

→ Développement de nouvelles méthodes "hybrides"



Objectifs

- Etude des méthodes pour le Lifelong learning et réaliser un état de l'art
- Implémenter au moins 3 méthodes parmi les plus performantes
- Réaliser un benchmark de ces solutions grâce au dataset Jacquard

Livrables :

- Logiciel : scripts développés
- Etude et analyse

Moyens mis à disposition : installations GPU





Plan

1. Contexte & Objectifs
- 2. Méthode de benchmarking**
3. État de l'art
4. Résultats
5. Conclusion & Perspectives

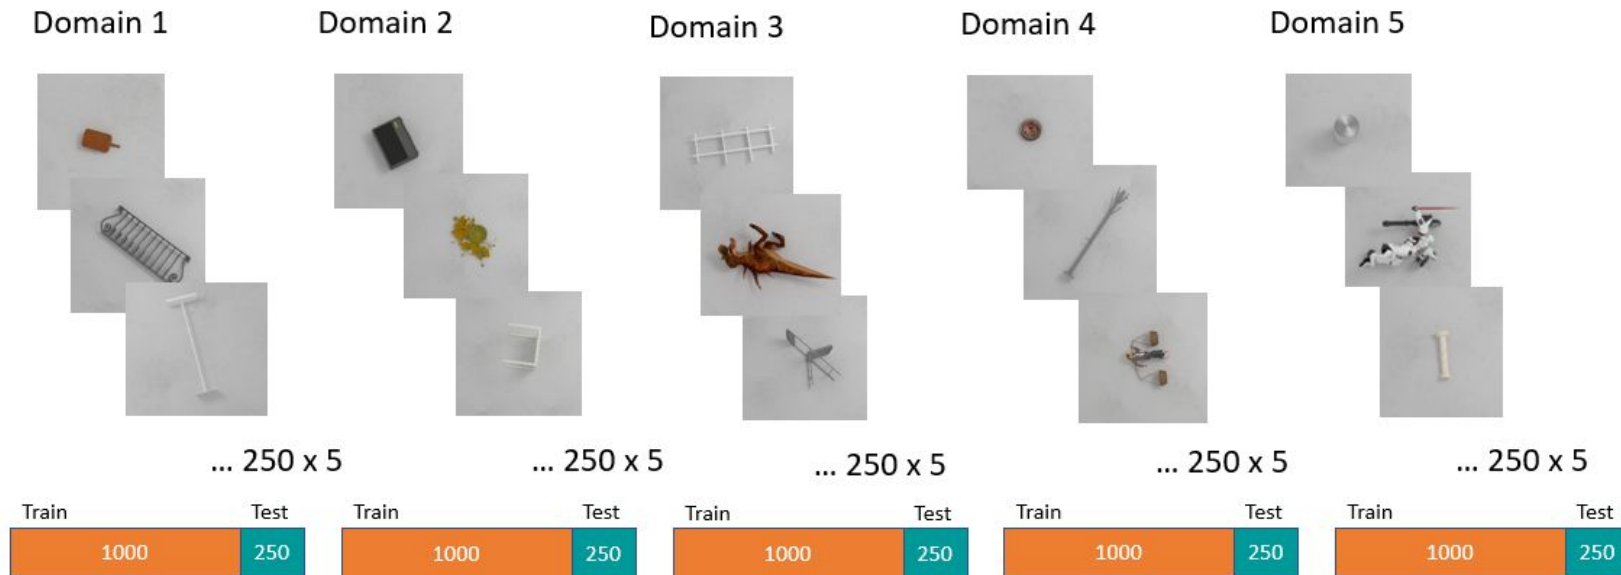
Jacquard

- BDD grande échelle & proche du terrain
- ShapeNet & expériences
- OpenSource

images RGB + profondeur
et annotations de prises de saisie réussie




Séparation en différents domaines



CNN, hyperparamètres, preprocessing

- AlexNet pour chaque implémentation
- hyperparamètres similaires
- même traitement réalisé sur les images en entrée





AlexNet architecture

Source : Scheme of the AlexNet used, ResearchGate

Métrique d'évaluation

- site associé à Jacquard : tests réalisés par simulation de saisie
- métrique simple : ok si l'angle entre prédiction et vérité < 30° & IOU (intersection sur union) > 25%



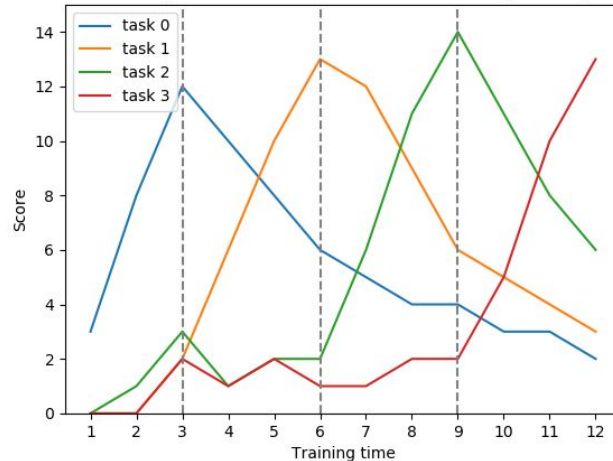
Source : Jacquard, Amaury Depierre, Emmanuel Dellandréa, Liming Chen, 2018




Plan

1. Contexte & Objectifs
2. Méthode de benchmarking
- 3. État de l'art**
4. Résultats
5. Conclusion & Perspectives

Apprentissage classique



Pas de méthode de lifelong learning
→ oubli catastrophique



Recours aux méthodes de lifelong learning
→ pas d'oubli

Implémentation pour :

- constater l'oubli catastrophique dans notre cas
- avoir une référence pour comparer l'efficacité des trois méthodes



État de l'art des méthodes de Lifelong Learning

Objectif : identifier les meilleures méthodes pour notre problème afin de les implémenter

Difficultés :

- Pas ou peu de méthodes de benchmarking → difficulté pour comparer les méthodes
- Recherche plutôt concentrée sur des tâches de classification → toutes les méthodes ne sont pas adaptables pour la régression
- Toutes les méthodes ne sont pas adaptées pour le traitement d'images
- Expérimentations souvent réalisées pour des tâches simples → les modèles dépassent rarement quelques couches



Lifelong Learning pour la classification (1)

Benchmark à partir de MNIST → classification des chiffres

- Split MNIST : séparation selon les classes (ex : Tâche 1 = {0; 1}, Tâche 2 = {2; 3}, ...)
- Permuted MNIST : une tâche correspond à une permutation fixe des pixels

Critique : tâche globalement “simple” (image taille 28x28, image binaire, pas de bruit dans les données, ...)

Lifelong Learning pour la classification (2)

Source : Three scenarios for continual learning, van de Ven, Gido M and Tolias, Andreas S. 2019.

Method	Task-IL	Domain-IL	Class-IL	Task-IL	Domain-IL	Class-IL
None – lower bound	85.15 (\pm 1.00)	57.33 (\pm 1.66)	19.90 (\pm 0.02)	81.79 (\pm 0.48)	78.51 (\pm 0.24)	17.26 (\pm 0.19)
XdG	98.74 (\pm 0.31)	-	-	91.40 (\pm 0.23)	-	-
EWC	85.48 (\pm 1.20)	57.80 (\pm 1.61)	19.90 (\pm 0.02)	94.74 (\pm 0.05)	94.31 (\pm 0.11)	25.04 (\pm 0.50)
Online EWC	85.22 (\pm 1.06)	57.60 (\pm 1.66)	19.90 (\pm 0.02)	95.96 (\pm 0.06)	94.42 (\pm 0.13)	33.88 (\pm 0.49)
SI	99.14 (\pm 0.11)	63.77 (\pm 1.18)	20.04 (\pm 0.08)	94.75 (\pm 0.14)	95.33 (\pm 0.11)	29.31 (\pm 0.62)
LwF	99.60 (\pm 0.03)	71.02 (\pm 1.26)	24.17 (\pm 0.51)	69.84 (\pm 0.46)	72.64 (\pm 0.52)	22.64 (\pm 0.23)
DGR	99.47 (\pm 0.03)	95.74 (\pm 0.23)	91.24 (\pm 0.33)	92.52 (\pm 0.08)	95.09 (\pm 0.04)	92.19 (\pm 0.09)
DGR+distill	99.59 (\pm 0.03)	96.94 (\pm 0.14)	91.84 (\pm 0.27)	97.51 (\pm 0.01)	97.35 (\pm 0.02)	96.38 (\pm 0.03)
RtF (see below)	99.66 (\pm 0.03)	97.31 (\pm 0.11)	92.56 (\pm 0.21)	97.31 (\pm 0.01)	97.06 (\pm 0.02)	96.23 (\pm 0.04)
Offline – upper bound	99.64 (\pm 0.03)	98.41 (\pm 0.06)	97.93 (\pm 0.04)	97.68 (\pm 0.01)	97.59 (\pm 0.01)	97.59 (\pm 0.02)

Split MNIST



Permuted MNIST

- Meilleure solution RtF mais difficile à implémenter dans notre cas (peu adaptée aux images et aux réseaux profonds)
- méthodes LwF et DGR retenues

LwF : Learning without Forgetting

Principe :

- augmente la taille de la dernière couche pour chaque nouveau domaine
- enregistre les sorties des anciens domaines issues du réseau original sur chaque image du nouveau domaine
- loss a un terme pour les anciens domaines qui tient compte de ces réponses enregistrées et un terme pour les nouveaux domaines
- ajuste l'ensemble des paramètres précédents et entraîne les nouveaux

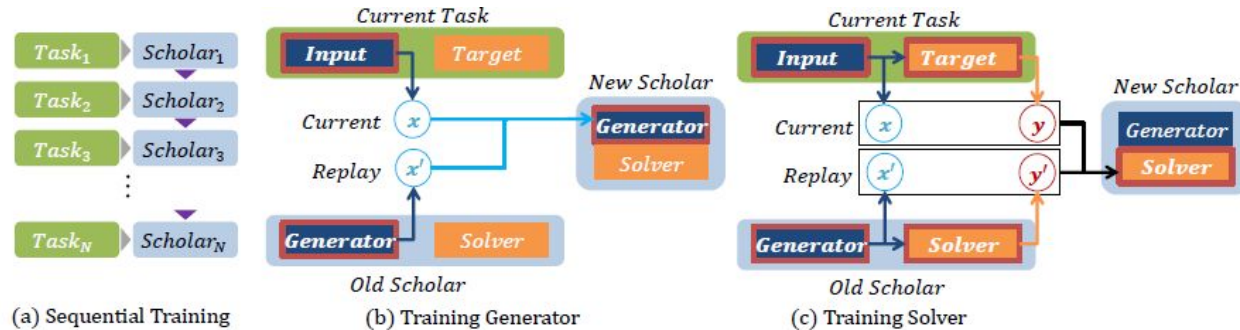


- random initialize + train
- fine-tune

Source : Learning without forgetting, Zhizhong Li, Derek Hoiem, 2017.

DGR : Deep Generative Replay

Principe : utiliser un GAN (réseau capable de créer des images) pour générer des données des tâches précédentes lors de l'arrivée de nouvelles données



Source : Continual Learning with Deep Generative Replay. H. Shin et al., 2017.



Lifelong Learning pour la régression

- Presque pas de résultats
- Extrait d'un article du 4 janvier 2021 :

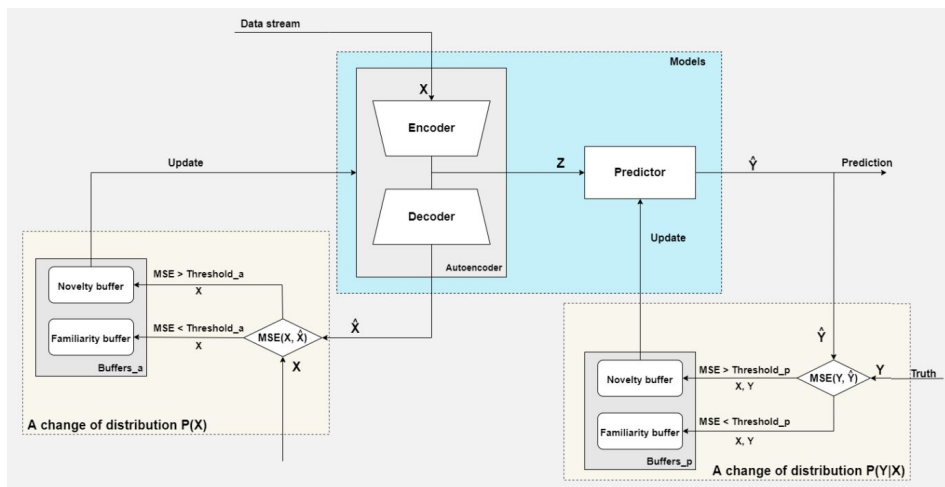
Abstract

Catastrophic forgetting means that a trained neural network model gradually forgets the previously learned tasks when retrained on new tasks. Overcoming the forgetting problem is a major problem in machine learning. Numerous continual learning algorithms are very successful in incremental classification tasks, where new labels appear frequently. However, there is currently no research that addresses the catastrophic forgetting problem in regression tasks as far as we know. This problem has emerged as one of the primary constraints in some applications, such as renewable energy forecasts. This article clarifies the problem-related definitions and proposes a new methodological framework that can forecast regression task targets and update itself by continual learning. The framework consists of forecasting neural networks and buffers, which store newly

Source : CLear: An Adaptive Continual Learning Framework for Regression Tasks. Yujiang He, Bernhard Sick. 2021.

- Mais cette article présente une nouvelle méthode pour la régression : CLear !
- La méthode limite efficacement l'oubli et semble être adaptable pour notre problème
- Méthode retenue pour le développement

CLear : Continual Learning for Regression tasks



→ 2 parties

Autoencoder :

- détermine si une données est nouvelle, i.e. éloignée des données déjà vues, les données nouvelles font dans un “novelty buffer”, les autres dans un “familiarity buffer”
- effectue une partie de la feature extraction

Predictor :

- effectue les prédiction
- détermine si le modèle est efficace sur chaque donnée, utilise le même système de buffer

Entraînement de l’autoencoder et predictor:

- à chaque nouvelle task
- l’apprentissage n’est effectué que sur les données du “novelty buffer”
- utilise une régularisation EWC (une méthode de lifelong learning) calculée sur toutes les données



Plan

1. Contexte & Objectifs
2. Méthode de benchmarking
3. État de l'art
- 4. Résultats**
5. Conclusion & Perspectives



Apprentissage classique

Training / Task	1	2	3	4	5
1	42,80%				
2	52,80%	54,40%			
3	48,00%	50,40%	46,80%		
4	49,60%	48,40%	45,60%	46,40%	
5	47,20%	50,80%	48,00%	42,40%	43,20%

- Catastrophic forgetting limité
- Somme des oublis relatifs : 0.39
- Précision moyenne après la dernière tâches : 46.32 %



DGR

Training / Task	1	2	3	4	5
1	46,40%				
2	39,20%	36,80%			
3	53,60%	49,20%	52,80%		
4	38,00%	36,00%	36,40%	34,00%	
5	40,00%	34,80%	37,60%	34,80%	35,60%

- Précision moyenne après la dernière tâches : 36.56 %
- Somme des oublis relatifs : 1.44
- Catastrophic forgetting !
- Perte de performance sûrement due au GAN qui est très long à entraîner et fonctionne avec des images de dimension 224 x 224.




CLeaR

Training / Task	1	2	3	4	5
1	6,80%				
2	54,40%	56,00%			
3	51,20%	55,20%	53,20%		
4	51,60%	52,00%	51,60%	50,00%	
5	56,40%	57,20%	50,80%	49,20%	54,80%

- L'apprentissage sur la 1ère tâche a une précision très faible
- Somme des oublis relatifs : 0.20
- Très peu de catastrophic forgetting
- Précision moyenne après la dernière tâches : 53.68 %

LwF

- Échec de l'apprentissage
- La loss ne converge
- Résultats de l'évaluation mauvais





Résumé des résultats

Critère	Apprentissage classique	CLeaR	DGR	LwF
Précision moyenne après la dernière tâche	46.32 %	53.68 %	36.56 %	
Somme des oublis relatifs	0.39	0.20	1.44	
Temps d'apprentissage	Court	Court	Très long	Court



Plan

1. Contexte & Objectifs
2. Méthode de benchmarking
3. État de l'art
4. Résultats
- 5. Conclusion & Perspectives**

Conclusion

- Codes
- Objections : méthode lifelong learning & benchmark




Perspectives

- Revoir les tâches (segmentation selon la forme...)
- Utiliser autres réseaux
- Validation grid search etc.
- Passer en réel


Domain 1

rectangular



Domain 2

hollow



Domain 3

complex





Domain 4

circular



Domain 5

long and thin





Des questions ?

Merci pour votre attention !